



72.80 - Big Data

Primera evaluación parcial

Fecha de entrega: 05/10/2026

Alumnos

Nombre	Legajo
Santiago Manuel Devesa	64223
Rosario Otegui	63708
Alicia Cobo Iglesias	69568
Ernest Elies Domingo	69613
Francisco Varela	64447

Profesores

Diego Mosquera Uzcaregui

1. Problema, usuarios y objetivos

Problema

Un proveedor de cloud tiene su ecosistema de datos implementado de manera que coexisten siete fuentes en archivos CSV (clientes, usuarios, recursos, soporte, marketing, NPS y facturación) y un stream de eventos en JSONL, con estructuras y frecuencias distintas, nulos, tipos ambiguos y un cambio de esquema a mitad del histórico.

Se propone integrarlas en un Data Lake y publicar indicadores de costos, uso y soporte. Los eventos necesitan actualización cercana al tiempo real, mientras que los maestros y la facturación, procesamiento diario o mensual.

Usuarios y preguntas

Usuarios	Preguntas
FinOps	¿Cuál es el costo y la cantidad de requests diarios por organización y servicio? ¿Qué costos son anómalos? ¿Qué servicios acumulan más costo en los últimos 14 días? ¿Cuál es la facturación mensual con créditos, impuestos y conversión a USD?
Soporte	¿Cómo evoluciona la cantidad de tickets críticos? ¿Qué proporción incumple el SLA? ¿Cuál es el CSAT promedio?
Producto / Usage	¿Cómo varía el uso de cada servicio? ¿Cuántos tokens de GenAI se consumen por día y organización, y a qué costo estimado? ¿Qué métricas de carbono hay disponibles?

Objetivos y criterios de éxito

Objetivo	Criterio medible
01. Integrar las fuentes	Las ocho fuentes tienen destino y modalidad de ingesta bien definidos.
02. Analizar costos y consumo	Es posible realizar consultas de costos y requests diarios por organización y servicio, y del top-N de servicios de los últimos 14 días, a través de Cassandra/AstraDB.
03. Seguir soporte	La consulta de tickets críticos y tasa de incumplimiento de SLA de los últimos 30 días responde desde Cassandra/AstraDB. El CSAT se calcula sobre las respuestas disponibles.
04. Detectar anomalías de costo	Cada costo atípico queda marcado con un flag o score, se conserva el dato original y el método de detección está justificado.
05. Incorporar métricas de Producto	La consulta de tokens de GenAI y costo estimado por día responde desde Cassandra/AstraDB. La ausencia de <code>carbon_kg</code> o <code>genai_tokens</code> se distingue del cero.
06. Trazabilidad y calidad	Cada registro de Bronze tiene <code>source_file</code> e <code>ingest_ts</code> . Los registros leídos deben terminar o en silver o en quarantine con su respectivo motivo.
07. Analizar facturación	La consulta de revenue mensual en USD, con créditos e impuestos, responde desde Cassandra/AstraDB.

2. Justificación de Big Data

El dataset provisto (43.200 eventos, ≈13 MB en 60 días) cabe en una sola máquina: su tamaño no justifica por sí solo un procesamiento distribuido. El diseño apunta a la escala de un proveedor real.

Dimensión	Aplicación al caso	Decisión de diseño
Volumen	Los eventos crecen con los clientes, los recursos y el tiempo.	Spark y Parquet particionado por fecha.
Velocidad	Uso y costos requieren actualización cercana al tiempo real, maestros y facturación son diarios o mensuales.	Streaming para eventos, batch para el resto.
Variedad	CSV y JSONL. La versión 2 de los eventos agrega campos.	Esquema explícito por fuente y esquema común para v1 y v2.
Veracidad	Nulos, números como texto, costos negativos.	Landing inmutable, reglas de calidad y quarantine.
Valor	Costos, consumo, facturación, SLA y uso de productos.	Un mart de Gold por pregunta de cada área.

3. Inventario y calidad inicial

La exploración se realizó con Pandas en [notebooks/01_exploracion_maestros.ipynb](#) y [notebooks/02_exploracion_eventos.ipynb](#). No se encontraron registros duplicados para las claves candidatas asignadas a continuación:

Fuente	Filas	Grano y clave	Ingesta
customers_orgs.csv	80	Organización; <code>org_id</code>	Batch diaria
users.csv	800	Usuario; <code>user_id</code>	Batch diaria
resources.csv	400	Recurso; <code>resource_id</code>	Batch diaria
support_tickets.csv	1.000	Ticket; <code>ticket_id</code>	Batch diaria
marketing_touches.csv	1.500	Interacción; <code>touch_id</code>	Batch diaria
nps_surveys.csv	92	Encuesta; <code>org_id</code> + <code>survey_date</code>	Batch diaria
billing_monthly.csv	240	Factura; <code>invoice_id</code>	Batch mensual
usage_events_stream/*.jsonl	43.200	Evento; <code>event_id</code> (120 archivos)	Micro-lotes

Hallazgos de calidad

Hallazgo	Tratamiento
11 organizaciones sin <code>nps_score</code> ; 19 encuestas sin <code>nps_score</code>	Calcular sobre las puntuaciones disponibles e informar la cobertura
139 usuarios sin <code>last_login</code> ; 232 con <code>last_login</code> anterior a <code>created_at</code>	Conservar la ausencia; validar la coherencia de fechas
240 tickets sin <code>resolved_at</code> , 254 sin <code>csat</code> ; 172 con <code>csat</code> sin <code>resolved_at</code>	Distinguir abiertos de errores; CSAT sobre las respuestas disponibles
<code>csat</code> entre 0 y 7	Abierta (sección 10)
137 facturas sin <code>credits</code> ; 13 subtotales negativos	Abierta (sección 10)
Tipo de cambio distinto de 1 en las 160 facturas en USD (entre 0,85 y 1,12); importes en ARS de magnitud similar a USD	Abierta (sección 10)
877 eventos sin <code>value</code> ; 2.075 sin <code>unit</code> , de los cuales 2.038 tienen <code>value</code>	<code>unit</code> se infiere de la métrica (cada una tiene una sola unidad); <code>value</code> nulo se valida según la métrica, con flag o quarantine
216 eventos con costo negativo (211 menores a -0,01)	Flag; abierta (sección 10)
1.309 <code>value</code> como texto, todos convertibles	Cast con valor de respaldo en Bronze
7.371 eventos anteriores a la creación de su recurso	Abierta (sección 10)
Cada archivo del stream abarca ≈60 días; el orden de llegada no es temporal	Upsert idempotente; el watermark no sirve para descartar datos
10.800 eventos v1 y 32.400 v2; <code>carbon_kg</code> (32.400 eventos) y <code>genai_tokens</code> (3.132) solo en v2	Esquema común con campos opcionales; ausencia no equivale a cero

4. Arquitectura de alto nivel

Se proponen dos caminos de entrada, batch (PySpark, para los CSV) y streaming (Structured Streaming, para los JSONL), escriben en las zonas del Data Lake. Los registros que no pasan la validación de Silver van a quarantine. Gold se carga en Cassandra/AstraDB para su consulta. Las responsabilidades de cada componente están en la sección 6.




Figura 1: Cloud Provider Analytics — Arquitectura propuesta (v1.1, 02/10/2026)

Fuente editable en texto: [diagramas/arquitectura-v1.1.mmd](#) (Mermaid).

5. Patrón arquitectónico

Se optó por el Patrón Híbrido: batch para maestros y facturación (ciclo diario o mensual) y streaming para los eventos de uso (actualización cercana al tiempo real). Los eventos necesitan reflejarse con poca latencia para FinOps, así que van por streaming.

Kappa no aplica ya que las fuentes son archivos, no un log reproducible, y modelar maestros como streams no aportaría ningún valor. Por su parte, Lambda duplicaría la lógica de agregación sobre los eventos.

6. Mapeo de requisitos a componentes

Componente	Responsabilidad	Objetivos	5V
PySpark batch	Leer los CSV con esquema explícito y escribir Bronze	O1, O3, O7	Variedad
Structured Streaming	Leer los JSONL en micro-lotes, deduplicar por <code>event_id</code> y recuperar el avance con checkpoints	O1, O2, O5	Velocidad
Landing	Conservar los originales sin modificar	O1, O6	Veracidad
Bronze	Tipos definidos; <code>source_file</code> e <code>ingest_ts</code>	O6	Variedad, veracidad
Silver	Normalizar, relacionar fuentes, tratar nulos y compatibilizar v1 y v2	O6	Veracidad
Quarantine	Guardar los registros inválidos con motivo y origen	O6	Veracidad
Analítica de anomalías (PySpark)	Marcar con flag o score los costos atípicos, conservando el dato original	O4	Valor
Gold	Marts por área con grano definido	O2, O3, O4, O5, O7	Valor
Cassandra/AstraDB	Tablas modeladas por consulta	O2, O3, O5, O7	Valor
Spark y Parquet particionado	Escalar con el histórico	O2, O5	Volumen

7. Diseño del Data Lake

Zona	Contenido	Regla de promoción
Landing	Archivos originales	Archivo legible y estructura reconocida
Bronze	Parquet con tipos definidos y origen registrado	Tipos y claves obligatorias válidos
Silver	Parquet normalizado, relacionado y con v1 y v2 compatibles	Reglas de calidad y relaciones verificadas
Gold	Parquet con indicadores de FinOps, Soporte y Producto	Grano definido y cálculos verificados
Quarantine	Parquet con registros inválidos, motivo y origen	N/A

Particiones. Eventos de Bronze y Silver por `event_date`; Gold diario por fecha y facturación por mes; maestros sin particionar ya que son archivos pequeños.

Nombres. Snake case:

- `landing/customers_orgs.csv`
- `bronze/usage_events/event_date=2025-07-03/`
- `silver/usage_events/event_date=2025-07-03/`
- `gold/org_daily_usage_by_service/usage_date=2025-07-03/`

Metadatos. Bronze agrega `source_file` e `ingest_ts`; Silver los conserva y suma `schema_version` en los eventos; Gold documenta fuentes, fecha de proceso y reglas de cálculo.

Retención. Landing se conserva; Bronze, Silver y Gold se regeneran por reprocesamiento; quarantine se conserva hasta su revisión.

8. Flujos de procesamiento

Flujo batch

Un job de PySpark lee los CSV de Landing con esquema explícito, agrega `source_file` e `ingest_ts` y escribe en Bronze. Corre por período (diario, mensual para facturación) y hace upsert por clave, de modo que sea idempotente. Todas las fuentes siguen Landing → Bronze → Silver → Gold. La siguiente tabla muestra lo que cambia en el tratamiento de cada fuente.

Fuente	Clave	Tratamiento en Silver	Mart de Gold
customers_orgs, users, resources	org_id, resource_id, user_id,	Dimensiones normalizadas	Enriquecen los demás marts
support_tickets	ticket_id	Fechas y severidad normalizadas; CSAT sobre las respuestas disponibles	tickets_by_org_date
billing_monthly	invoice_id	Importes en USD, con créditos e impuestos	revenue_by_org_month
marketing_touches, nps_surveys	touch_id; org_id, survey_date	Normalizadas y relacionadas con la organización	Enriquecen las dimensiones

Flujo streaming

1. Structured Streaming lee el directorio de JSONL con esquema explícito, con los campos de la v2 como opcionales.
2. Bronze conserva el evento con `source_file` e `ingest_ts`; `value` se convierte a número con valor de respaldo.
3. Se deduplica por `event_id`.
4. Silver compatibiliza v1 y v2 y envía los registros inválidos a quarantine.
5. Gold se actualiza por upsert con clave natural: `org_daily_usage_by_service`, `cost_anomaly_mart` y `genai_tokens_by_org_date`. Los checkpoints recuperan el avance.
6. Los marts de Gold se publican en Cassandra/AstraDB.

9. Ejemplo de flujo batch con lógica MapReduce

Costo y requests diarios por organización y servicio (`org_daily_usage_by_service`):

- **Map:** cada evento válido emite la clave (`org_id`, `fecha`, `servicio`) con su costo y, si la métrica es `requests`, su `value`. Los inválidos van a quarantine.
- **Shuffle:** se agrupan los eventos con la misma clave, aunque vengan de archivos distintos.
- **Reduce:** se suman costos y requests.

La suma es asociativa, así que cada partición puede pre-agregar sus eventos antes del Shuffle (combiner) y reducir los datos que viajan entre nodos. En el dataset, puede suceder que los eventos de una misma clave lleguen en archivos distintos, por ejemplo, (`org_cvs4f8cg`, `2025-08-17`, `networking`) junta seis eventos de cinco archivos: 4,8360 USD y 376 requests.

10. Supuestos, riesgos y decisiones abiertas

Supuesto. Las frecuencias de ingesta batch (diaria y mensual) son una decisión de diseño: no se pueden inferir de los archivos provistos.

Riesgos y mitigaciones

Riesgo	Mitigación
Datos de calidad desigual	Reglas verificables; quarantine con motivo y flags en lugar de descartar
Cambio de esquema v1 a v2	Esquema explícito con campos opcionales; no imputar cero
Duplicados por reprocesamiento	Deduplicación por <code>event_id</code> , upsert por clave natural y checkpoints
Llegada fuera de orden	No descartar por watermark; upsert y recomputo desde Silver
Facturación ambigua	Consultar, documentar la regla y conservar los importes originales

Decisiones abiertas

Tema	Opciones
Costos negativos	Ajustes válidos, error a quarantine o conservar con flag
Eventos anteriores a la creación del recurso	Quarantine o conservar con flag; el <code>created_at</code> del maestro puede no ser confiable
<code>credits</code> vacío	Cero o dato faltante
Subtotales negativos	Notas de crédito o error
Moneda y tipo de cambio	Verificar con la cátedra; calcular en USD con la tasa de la factura
Escala del CSAT (se observan valores de 0 a 7)	Fijar el rango válido; fuera de rango pasa a nulo con flag
Método de anomalías de costo	Percentiles por servicio o z-score robusto por organización y servicio

11. Estimación de esfuerzo, roles y recursos

Horas-persona preliminares para la segunda entrega y la entrega final: ≈ 61 h (rango 55–65).

Roles

Cada área tiene un responsable y un apoyo que revisa su código. Integración, revisión y pruebas del flujo completo son compartidas.

Integrante	Rol principal	Apoyo en
Santiago Manuel Devesa	Ingesta batch y pruebas	Streaming
Rosario Otegui	Silver y calidad	Gold
Alicia Cobo Iglesias	Streaming	Silver
Ernest Elies Domingo	Gold y anomalías	Serving
Francisco Varela	Serving y documentación	Ingesta batch

Estimación de esfuerzo

Paquete de trabajo	Resultado	Responsable	Horas	Instancia
Ingesta batch (Landing y Bronze)	Maestros y facturación en Parquet con origen registrado	Santiago	9	Segunda entrega
Silver y quarantine	Datos normalizados, reglas de calidad y rechazados	Rosario	13	Segunda entrega
Streaming de eventos	Micro-lotes, checkpoints, deduplicación por <code>event_id</code> y esquemas v1 y v2	Alicia	12	Segunda entrega
Gold	Marts de FinOps, Soporte y Producto	Ernest	8	Segunda y final
Anomalías de costo	Flag y score sobre <code>cost_anomaly_mart</code>	Ernest	4	Entrega final
Serving en Cassandra/AstraDB	Tablas por consulta y carga; cinco consultas	Francisco	6	Segunda y final
Pruebas	Transformaciones, reglas de calidad e idempotencia	Santiago	4	Entrega final
Documentación y demo	README, diagrama final, evidencias y defensa	Francisco	5	Entrega final
Total			61	

Recursos

Recurso	Uso
GitHub	Repositorio y control de versiones
PySpark y Structured Streaming	Procesamiento batch y de eventos
Parquet	Zonas del Data Lake
Cassandra/AstraDB	Consulta de los marts Gold

12. Próximos pasos

Hacia la segunda entrega (16/11/2026):

1. Incorporar las correcciones del feedback y resolver las decisiones abiertas que bloquean Silver.
2. Ingestar al menos tres maestros a Bronze con esquema explícito, `source_file`, `ingest_ts` y deduplicación.
3. Procesar los eventos con Structured Streaming hacia Bronze, con deduplicación por `event_id` y checkpoints.
4. Construir Silver con reglas de calidad, compatibilidad v1 y v2 y quarantine con muestras.

5. Construir `org_daily_usage_by_service` y cargarlo en Cassandra/AstraDB con dos consultas ejecutadas.
6. Verificar que una re-ejecución no genera duplicados, con conteos antes y después.
7. Actualizar el diagrama con lo implementado y documentar la puesta en marcha en el README.